Lesson 8-14

Files

Tags

Lesson 8. Introduction to Neural Networks

- Classification
- Perceptron, , XOR (NAND), neurons, VC dimenstion
- Discrete, contiunious
- MLE
  - log, product, sum
- Cross entropy, RMSE
- Cost function vs Accuracy
- Gradient descent, chain rule, backprop

Lesson 9. Training Neural Networks

- training optimization
- overfitting vs underfitting
- regularization
- dropout
- batch normalization
- local minima
- random restart
- early stopping
- vanishing gradient

- activation functions
- batch vs stochastic gradient descent
- learning rate decay
- momentum
- error functions

Lesson 10

(생략)

Lesson 12. Embeddings & Word2vec

1. 단어 임베딩(Word Embedding)이란 텍스트를 구성하는 하나의 단어를 수치화하는 방법

   word → embedded vector : 이 벡터를 embeddings 이라 함

   text data의 차원 축소 + 단어 간 연관관계 파악(ex. 시제,성별,..)

   문맥 속 단어 파악하기 때문에, 편향되거나 잘못된 정보가 있으면 잘못 임베딩 됨

2. one-hot encoding의 비효율성을 개선(행렬 연산 복잡)

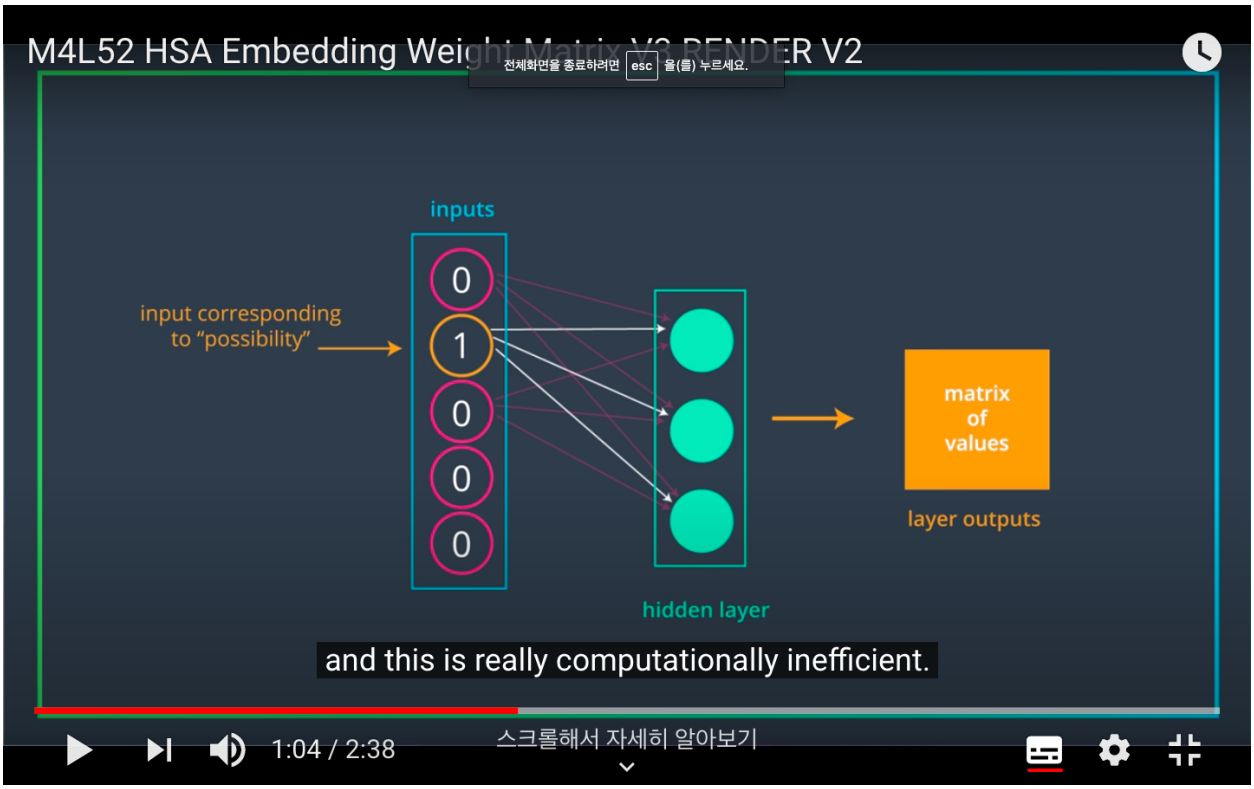

word → integer token(input) → embedding layer → embedding weight matrix → embedding vector(output)

one-hot의 weight matrix를 곱하면 output은 한 개의 행

이때 embedding weight matrix를 lookup table 이라고도 함. lookup table 은 훈련 과정에서 학습됨columns 개수가 embedding dimension(보통 몇백개)

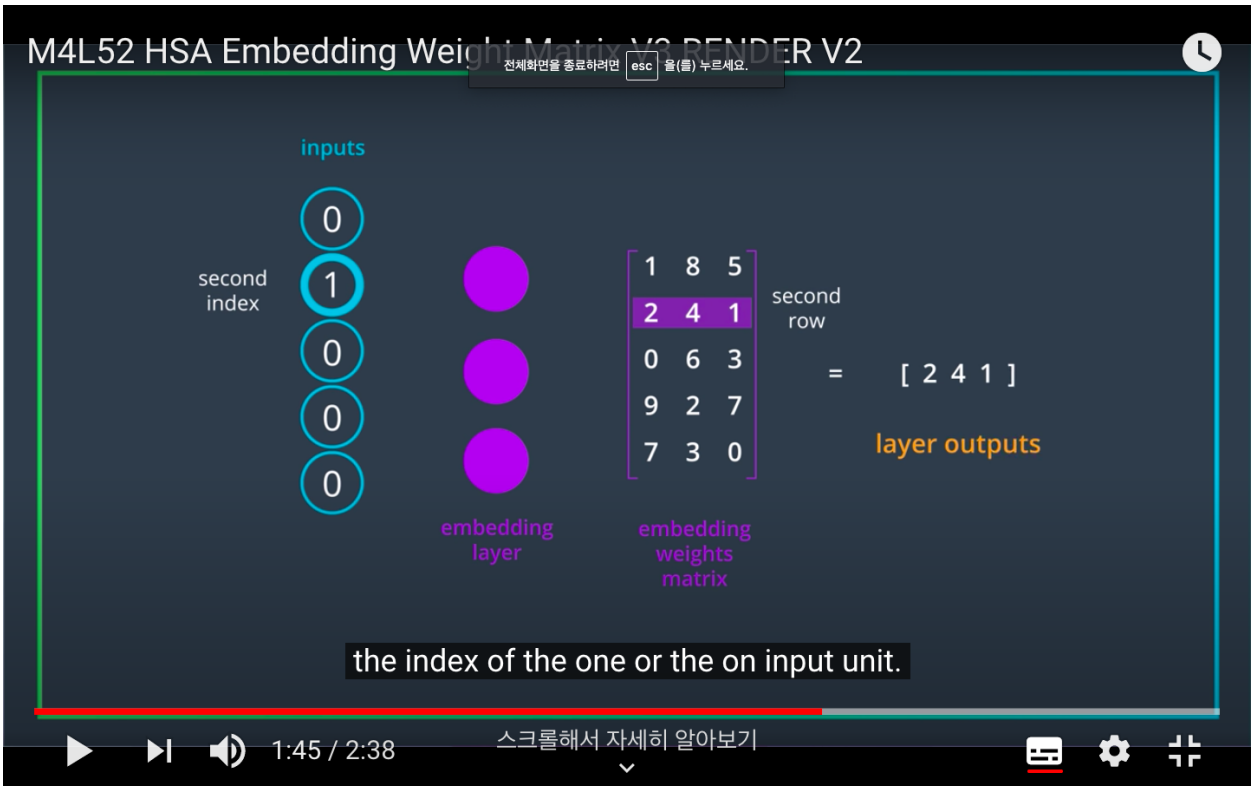

그림 20.5.4 : CBOW 임베딩 예

https://datascienceschool.net/view-notebook/6927b0906f884a67b0da9310d3a581ee/

3. Word2Vec

같은 문장 안에 등장한 단어는 비슷한 벡터 값을 가짐

1) CBOW(Continuous Bag Of Words)

문맥 속 '주변 단어'로 '현재 단어'를 예측

2) Skip-gram

'현재 단어'로 '주변 단어'를 예측 (k : windowsize)

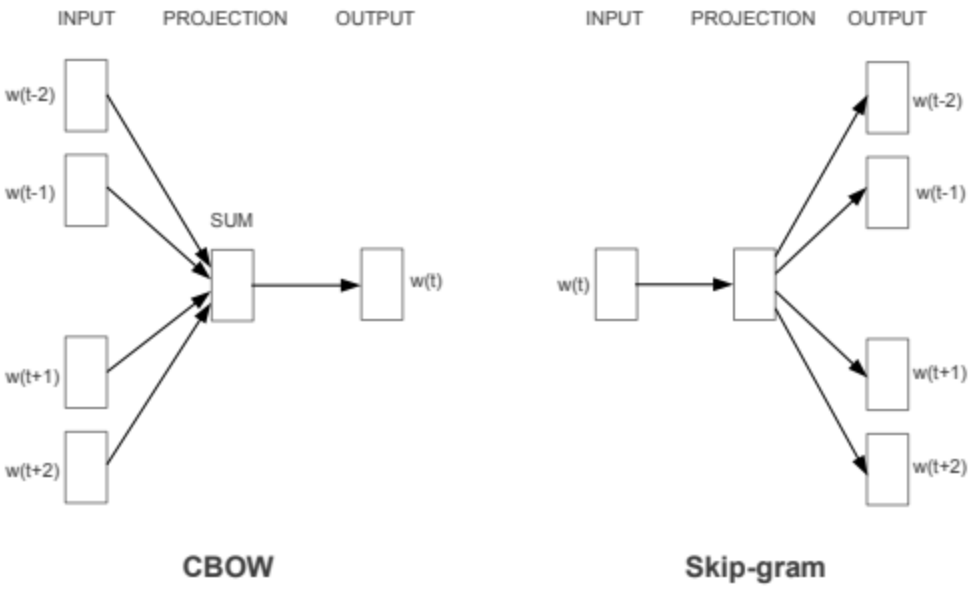

3) word2vec

기본적인 임베딩 모형에 subsampling, negative sampling 등의 기법을 추가된 형태

(1) Loading Data

(2) Pre-processing : util 패키지 내 preprocess 함수 사용(부호를 토큰화 <PERIOD>)

(3) Dictionaries : lookup table 만들기 vocab ↔ int (가장 많이 등장:0 ~ 덜 등장:n) list로 저장

(4) Subsampling : 많이 등장한 common words 삭제 (f(wi)는 해당 단어 등장한 비율, t 는 사용자가 지정 값 0.00001 권장)

(5) Making batches : 크기 C의 윈도우

Lesson 13

1. Model Architecture

- Embedding layer
  - 단어를 벡터로
- LSTM Layer
  - 각 LSTM cell의 입력:
    - 현재 t의 입력 벡터(=1층짜리 LSTM같은 경우, t 번째 단어 임베딩)
    - 이전 셀에서 가지고 있는 정보
  - 각 LSTM cell의 출력:
    - 벡터
    - 이 벡터들을 fully-connect
- Sigmoid output layer
  - 각 LSTM cell의 출력 벡터들을 fully-connect한 후 softmax에 태움

2. Data Preprocessing

- 필요없는 단어 제거, 줄바꿈/구두점 이런것들 다 띄어쓰기로 대체, 정규화
- Word → integer, integer → vector
- 너무 크기가 크거나 작은 텍스트는 훈련에서 배제
- 긍정의견은 1, 부정의견은 0으로 변경
- sequence padding:
  - 길이가 다른 문장들을 고속병렬처리하기 위함

3. Training

- torch 문법
- 나중에 쓰게될 프레임워크 따라서 배웁시다. 저는 tensorflow 파라서...
- AutoML 같은 거 쓸거면 이 조차도 필요없음

- 지금 배우는 RNN 감정분석은 꽤나 널리 알려진거라 거의 제품화 되어있을거에요
- Train, Validation, Test
  - Train vs Validation: parameter(=알고리즘이 결정하는 값)의 검증
  - Train/Validation vs Test: hyperparameter(=아직까지는 사람이 결정하는 값)의 검증

Lesson 14

(생략)